

الجمهورية العربية السورية  
المعهد العالي للعلوم التطبيقية والتكنولوجيا  
قسم المعلومات  
العام الدراسي 2017/2018

# نظام خبير لتقييم مقروئية نصوص اللغة الانكليزية وفق عدّة مستويات مشروع السنة الرابعة

إعداد

فاروق حجابو

إشراف

م. رياض سنبل

د. غيداء ريداوي

2 أيلول 2018

# الملخص

نص

شكر

نص

# المحتويات

i	الغلاف
ii	الملخص
iii	شكر
iv	المحتويات
vii	قائمة الأشكال
ix	قائمة الجداول
x	الاختصارات
xi	المصطلحات
1	1 التعريف بالمشروع
1	1.1 مقدمة
1	2.1 أهمية المشروع وتطبيقاته
2	3.1 المتطلبات
2	1.3.1 المتطلبات الوظيفية

3	المتطلبات غير الوظيفية	2.3.1
4	الدراسة المرجعية	2
4	تعلم الآلة	1.2
5	تصنيفات تعلم الآلة	1.1.2
6	المراحل اللازمة لتطبيق تعلم الآلة	2.1.2
7	خوارزميات تعلم الآلة	3.1.2
10	معايير التقييم	4.1.2
12	معالجة اللغات الطبيعية	2.2
14	الأوراق العلمية	3.2
16	تصميم النظام	3
16	منهجية العمل	1.3
17	المخططات الصندوقية للنظام	2.3
17	المعطيات المستخدمة	3.3
17	One Stop English Corpus (OSE)	1.3.3
20	الميزات المستخدمة	4.3
20	الخوارزميات المستخدمة	5.3
21	التصميم البرمجي والتنجز	4
21	قراءة المعطيات	1.4

22	.....	استخراج الميزات	2.4
26	.....	cleaners الحزمة	1.2.4
26	.....	features الحزمة	2.2.4
27	.....	featuresets الحزمة	3.2.4
27	.....	extractors الحزمة	4.2.4
28	.....	nlp الحزمة	5.2.4

# قائمة الأشكال

1.2	الخطأ في العينة الواحدة في نموذج الـ SVM . . . . .	8
2.2	مستقيم يفصل صفيين بهامش أعظمي . . . . .	9
3.2	معطيات التدريب غير قابلة للفصل باستخدام مستقيم . . . . .	9
4.2	مثال عن عملية التكتيل . . . . .	12
5.2	مثال عن الشجرة النحوية . . . . .	13
6.2	مثال عن بيان التبعية . . . . .	13
1.3	المخطط الصندوقي للحصول على المصنّف وتقييم أدائه . . . . .	18
2.3	المخطط الصندوقي لاستخدام المصنّف . . . . .	18
1.4	مخطط الصفوف للحزمة datasets . . . . .	22
2.4	مخطط الصفوف للحزمة datasets.corpora . . . . .	23
3.4	مخطط الصفوف للحزمة datasets.writers . . . . .	24
4.4	مخطط الصفوف للحزمة featureengineering . . . . .	25
5.4	مخطط الصفوف للحزمة featureengineering.cleaners . . . . .	26

27	. . . . .	.featureengineering.features	الحزمة للصفوف	عينة من مخطط	6.4
28	. . . . .	.featureengineering.featuresets	الحزمة للصفوف	عينة من مخطط	7.4
29	. . . . .	.featureengineering.extractors	الحزمة للصفوف	مخطط	8.4
30	. . . . .	.nlp	الحزمة للصفوف	عينة من مخطط	9.4



## قائمة الجداول

19	عينة من جمل ال OSE المصنفة إلى ثلاثة مستويات . . . . .	1.3
20	إحصائيات وصفية لنصوص ال OSE . . . . .	2.3

# الاختصارات

SVM	Support Vector Machine
SMO	Sequential Minimal Optimization
NLP	Natural Language Processing
OSE	One Stop English Corpus

# المصطلحات

Artificial Intelligence	الذكاء الصناعي
Machine Learning	تعلم الآلة
Natural Language Processing	معالجة اللغات الطبيعية
Supervised Learning	التعلم تحت الإشراف
Unsupervised Learning	التعلم بدون إشراف
Semi-Supervised Learning	التعلم نصف المشرف عليه
Reinforcement Learning	التعلم بالتعزيز
Classification	التصنيف
Regression	الانحدار
Training Set	معطيات التدريب
Test Set	معطيات الاختبار
Training Instance	مثال تدريبي
Accuracy	الصحة
Precision	الدقة
Recall	الإرجاع
Clustering	التجميع
Features	ميزات
Feature Extraction	استخراج الميزات
Regularization	التنظيم
Kernel	نواة

Linear Kernel	النواة الخطية
Polynomial Kernel	النواة الحدودية
Gaussian Kernel	النواة الغاوسية
Hyperparameter	بارامتر فوقى
Classifier	مُصنّف
Morphological Analysis	التحليل الصرفى
Tokenization	التقطيع
Stemming	التشذيب
Chunking	التكتيل
Parsing Tree	الشجرة النحوية
Dependency Parsing	تحليل التّبعية
Dependency Graph	بيان التبعية
Anaphora	الإحالة
Design Patterns	الأنماط التصميمية

# الفصل الأول

## التعريف بالمشروع

يُجهّد هذا الفصل للمشروع، حيث يُبيّن فكرة المشروع وأهميتها والأهداف المرجوة منه. ويذكر المتطلبات الوظيفية وغير الوظيفية للمشروع.

### 1.1 مقدمة

تلعب القراءة دور مهم جداً في تعلم لغة جديدة أو لاكتساب معارف ومعلومات حول موضوع معيّن. بالتالي فإن أي مسببات للصعوبة أثناء عملية القراءة ستؤثر سلباً في عملية التعلم واكتساب المعارف. فاهتم الباحثون بالأسباب التي تؤدي إلى صعوبة في قراءة النصوص وتأثيراتها على القراء. وقد تمت دراسة الخواص اللغوية التي تسبب صعوبة في قراءة النصوص؛ مثل المفردات، والقواعد، والترابط. إنّ الهدف العريض من هذا المشروع هو بناء تطبيق لتقييم صعوبة قراءة نص معيّن.

### 2.1 أهمية المشروع وتطبيقاته

إنّ بناء تطبيق يقوم بتقييم صعوبة قراءة نص بشكل آلي هو أداة مفيدة. فيمكن للاستاذة استخدامه لمساعدتهم في اختيار نصوص مناسبة لطلابهم سواء أثناء الجلسات التعليمية أو في الاختبارات. خصوصاً استاذة تعليم

اللغات. كما أنه بوجود معلومات هائلة متاحة على الانترنت، فإن هذا التطبيق سيساعد الطلاب على اختيار ما يناسبهم أثناء عملية تعلمهم عن موضوع معين أو قراءة مقالات حول مجال ما. وبعيداً عن سياق الأمور التعليمية، يمكن لتحليل صعوبة نص أن تكون مناسبة و لازمة في عدّة سيناريوهات مثل تحليل النصوص القانونية والقضائية. أيضاً يمكن للكُتّاب الاستفادة من هكذا تطبيق أثناء عملية كتابتهم، سواء كتابة مقال علمي أو مقال صحفي أو خبر أو غيرها.

ولإعطاء تطبيقات ملموسة بشكل أكثر. سنتحدث لاحقاً عن عدد من النصوص التي تم استخدامها ضمن المشروع، حيث أن مجموعة اساتذة يختارون نص معيّن ويعيدون صياغته إلى ثلاثة نصوص بما يناسب طلاب من ثلاثة مستويات. أي أنه ستم المحافظة على فحوى النص أكثر ما يمكن، ولكن صياغته ستختلف لتناسب ثلاث مستويات من الطلاب. فوجود هذا التطبيق سيساعدهم في معرفة إذا ما كانت صياغتهم مناسبة أم لا، وهل يحتاجون إلى تبسيطه أكثر من ذلك.

أيضاً يمكن استخدام هذا النص لمساعدة اساتذة اللغة الإنكليزية. سواء في المعهد العالي أو المدارس أو غيرها. فعادةً يوجد قسم في امتحان اللغة لتقييم قدرات الطالب على فهم نص جديد في اللغة الإنكليزية reading comprehension. إن ما يقوم به الاساتذة أحياناً هو اختيار نص من الكتاب نفسه لم يتم عرضه بشكل مسبق على الطلاب. أو اختيار نص من الانترنت، وباستخدام هكذا تطبيق تصبح هذه العملية أكثر سهولة ليكون هذا النص أكثر ملائمة لمستوى الطلاب، وبالتالي أفضل لتقييم الطلاب بشكل سليم وعادل وأكثر موضوعية.

### 3.1 المتطلبات

نسرد فيما يلي المتطلبات الوظيفية والغير وظيفية للمشروع.

#### 1.3.1 المتطلبات الوظيفية

1. بناء تطبيق لتقييم سهولة قراءة نص مكتوب باللغة الانكليزية. تحت ما يلي:

(أ) المصنّف المستخدم (المستويات التي يتم تصنيف صعوبة النص وفقها، وعددها، والتفاوت بينها) يتعلق بالمعطيات المستخدمة للتدريب.

(ب) يُتيح التطبيق للمستخدم اختيار واحد من عدّة مُصنّفات لتصنيف نص مُدخل.

- (ج) تنجيز مُصنّف واحد على الأقل.
2. بناء مكتبة برمجية كإطار عمل لاستخراج الميزات لنص أو مجموعة نصوص.

### 2.3.1 المتطلبات غير الوظيفية

1. الفعاليّة. يجب أن يحقق النظام نسبة صحّة مقبولة.
2. الكفاءة. يستغرق التطبيق وقت بسيط لتصنيف نص معيّن.
3. يتم تطوير كامل النظام باستخدام لغة البرمجة جافا.
4. قابلية التوسّع. يمكن إضافة مصنّفات جديدة باستخدام المعطيات ذاتها أو باستخدام معطيات جديدة.
5. يجب أن تحقق مكتبة استخراج الميزات ما يلي:
  - (أ) قابلية التوسّع. يمكن لمستخدم المكتبة تنجيز ميزات جديدة.
  - (ب) سهولة الاستخدام. يمكن لمستخدم المكتبة استخدام الميزات المنجّزة بشكل مسبق بسهولة والتركيب بينها.

## الفصل الثاني

# الدراسة المرجعية

يبيّن هذا الفصل الدراسة المرجعية للمشروع. يبدأ بتقديم مفاهيم تعلّم الآلة ومراحلها المختلفة والمعايير المعتمدة لتقييمها. ويقدم مفاهيم ومراحل معالجة اللغات الطبيعية. وأخيراً يسرد بعض الأوراق الأبحاث العلمية المتعلقة بهذا المشروع، ويوضح المنهجيات المتبعة فيها.

## 1.2 تعلم الآلة

تعلم الآلة Machine Learning هو فرع جزئي من الذكاء الاصطناعي Artificial Intelligence. يُقصد بتعلم الآلة مجموعة الأدوات والمفاهيم والمنهجيات المستخدمة لبرمجة الحواسيب بطريقة تسمح لهذه الحواسيب بالتعلم من المعطيات [25].

ويمكن أيضاً تعريفه بشكل أكثر عمومية كالتالي:

“Machine Learning is the field of study that gives computers the ability to learn without being explicitly programmed.”

–Arthur Samuel, 1959

كما يعتبر التعريف التالي تقني وأكثر دقة:



“A computer program is said to learn from experience  $E$  with respect to some task  $T$  and some performance measure  $P$ , if its performance on  $T$ , as measured by  $P$ , improves with experience  $E$ .”

–Tom Mitchell, 1997

على سبيل المثال، النظام الذي يقوم بفلتر الإيميلات إلى إيميلات مؤذية spam وإيميلات غير مؤذية non-spam، يستخدم منهجيات تعلم الآلة. يقوم هذا النظام بتعلم طريقة التمييز بين هذين النوعين من الإيميلات باستخدام عدد كبير من الأمثلة والمعطيات المصنفة مسبقاً. نسمي هذه المجموعة من الأمثلة بمعطيات التدريب Training Set، وكل مثال منها نسميه مثال تدريبي Training Instance.

في هذه الحالة، المهمة  $T$  هي تصنيف الإيميلات الجديدة إلى إيميلات مؤذية وإيميلات غير مؤذية، الخبرة  $E$  هي مجموعة معطيات التدريب، ومؤشر قياس الأداء  $P$  يمكن تعريفه بعدة طرق؛ فمثلاً يمكننا استخدام نسبة عدد الإيميلات التي تم تصنيفها بشكل صحيح إلى عدد الإيميلات الكلي (هذا المعيار يسمى الصحة Accuracy كم سنرى لاحقاً).

### 1.1.2 تصنيفات تعلم الآلة

يمكن تصنيف أنظمة تعلم الآلة وفق عدة معايير. التصنيف الأكثر شهرة يعتمد على آلية التدريب، وهو كالتالي:

- التعلم تحت الإشراف Supervised Learning: وهي حالة أن تكون الأمثلة التدريبية متوفرة مع الخرج label المرتبط بها. وهذه حالة مثال تصنيف الإيميلات المطروح سابقاً. حيث أن معطيات التدريب هي مجموعة كبيرة من الإيميلات المصنفة مسبقاً من قبل البشر إلى إيميلات مؤذية وإيميلات غير مؤذية.
- التعلم بدون إشراف Unsupervised Learning: وهي حالة أن تكون معطيات التدريب موجودة ولكنها غير مصنفة unlabeled أو غير مرتبطة بخرج معين. على سبيل المثال، قد ترغب شركة في تصنيف زبائنهم إلى عدة مستويات، زبائن من الدرجة الأولى، زبائن من الدرجة الثانية، وهكذا. فيمكن استخدام تعلم الآلة لاكتشاف بعض الأنماط الموجودة في معطيات الزبائن واكتشاف هكذا تصنيف. وهذا ما يُعرف بالتجميع Clustering.
- التعلم نصف المشرف Semi-Supervised Learning: وهي حالة وسيطة بين التصنيفين السابقين. تكون فيها بعض أمثلة التدريب مرتبطة بخرج معين (غالباً تشكل النسبة الصغيرة)، وتكون باقي الأمثلة غير

مرتبطة بخرج. تنطبق هذه الحالة على مثال تصنيف الإيميلات في حال لم تكن جميع معطيات التدريب مصنفة بشكل مسبق.

- التعلم بالتعزيز Reinforcement Learning: وهي الحالة التي يتخاطب فيها النظام مع بيئة أخرى. تقدم له هذه البيئة نتائج feedback بناءً على أفعاله. هذا الصنف ينطبق على الخوارزميات المستخدمة لتدريب الأنظمة التي تتعلم الألعاب. حيث يقوم النظام بمجموعة من الأفعال actions ضمن بيئة اللعبة، وبناءً على النتائج (تحسن نتيجته أو انخفاضها) يغير أفعاله اللاحقة.

وعلى وجه الخصوص يمكن تصنيف التعلم تحت الإشراف بحسب نوع الخرج المرتبط بمعطيات التدريب. تصنف بشكل أساسي عريض كالتالي:

- التصنيف Classification: يكون الخرج المرتبط بكل مثال تدريبي هو صف class محدد من مجموعة صفوف. عدد هذه الصفوف قد يكون 2، 3، إلخ. في مثال تصنيف الإيميلات السابق، عدد الصفوف هو 2، حيث أن كل مثال تدريبي (إيميل معين من معطيات التدريب) هو إما مؤذي أو غير مؤذي.
- الانحدار Regression: يكون الخرج المرتبط بكل مثال تدريبي هو عدد حقيقي. مثل مسألة التنبؤ بسعر منزل بمعرفة معلومات عنه مثل مساحته، عدد الغرف، إلخ.

## 2.1.2 المراحل اللازمة لتطبيق تعلم الآلة

إذا عدنا إلى مثال تصنيف الإيميلات، حيث قلنا أن معطيات التدريب هي مجموعة من الإيميلات المصنفة بشكل مسبق إلى إيميلات مؤذية وإيميلات غير مؤذية. يمكن أن نسأل هنا: ما هو تحديداً الدخل؟ أي كيف سنعتبر عن الإيميل؟ بالطبع يمكن اعتبار الإيميل كنص؛ فهو مجموعة من الكلمات والرموز. ولكن كما سنرى لاحقاً، من الصعب على معظم خوارزميات تعلم الآلة التعامل مع نص خام. ولذلك هناك مرحلة تسبق مرحلة تنفيذ خوارزميات تعلم الآلة وهي مرحلة تحويل النص إلى ما يسمى بالميزات Features.

فمثلاً يمكن أن نعبر عن نص الإيميل بميزاته، مثل عدد الكلمات، عدد الجمل، تواتر وجود كلمات مفتاحية محددة، إلخ. نلاحظ الآن في هذه الحالة أننا نتعامل مع الإيميل كشعاع من الميزات feature vector وهذا أمر مناسب جداً للعديد من خوارزميات تعلم الآلة. أيضاً إن الميزات التي ذكرناها هي ميزات عددية numerical features، ولكن بشكل عام يمكن أن تكون الميزات هي ميزات نصية string features أو ميزات صنفية categorical features، إلخ. ويمكن أيضاً تمثيل الميزات بشكل مختلف أو أكثر دقة مثل تصنيف الميزات

العددية إلى ميزات مستمرة continuous features وميزات متقطعة discrete features. وتعود طريقة الترميز إلى التطبيق أو خوارزميات تعلم الآلة المستخدمة. تسمى هذه المرحلة بمرحلة استخراج الميزات Feature Extraction.

في التطبيقات الواقعية تسبق المرحلة السابقة مرحلتين أساسيتين. مرحلة تجميع المعطيات، ومرحلة تنظيفها. تتم عملية تجميع المعطيات بحسب التطبيق. فمثلاً قد تكون المعطيات هي نتيجة استبيانات، أو إحصائيات، أو تم الحصول عليها من مواقع إلكترونية، إلخ. مرحلة تنظيف المعطيات تهدف إلى التأكد سلامة المعطيات قبل استخدامها. وقد تتم هذه العملية بشكل يدوي أو بشكل مؤتمت وذلك بحسب مصدر المعطيات ونظافتها.

### 3.1.2 خوارزميات تعلم الآلة

كما رأينا في الفقرة 1.1.2، هناك العديد من أصناف المسائل الممكن حلها باستخدام تعلم الآلة. تصنف خوارزميات تعلم الآلة تبعاً لصنف المسألة التي تقوم بحلها. فمثلاً يمكن استخدام الانحدار الخطي Linear Regression لحل مسائل الانحدار [25]. أو استخدام خوارزمية K-Means Clustering لحل مسائل التجميع [25]. سنمهد في هذه الفقرة لأهم خوارزمية مستخدمة في هذا المشروع. وهي ال SVM.

#### خوارزمية ال SVM

إن كلمة SVM هي اختصار لـ Support Vector Machine. وهي خوارزمية تصنيف شهيرة وواسعة الاستخدام في تطبيقات تعلم الآلة. تعتبر خوارزمية قوية حيث أنها تستند على أساس رياضي متين، ولها عدد من الخصائص المهمة. يمكن تقديم هذه الخوارزمية بعدة طرق. سنقدمها بطرح مسألة الأمثلة التي تقوم بحلها.

بدايةً لنفرض أن مسألتنا هي مسألة تصنيف وعدد الصفوف هو 2. نرمز بـ  $(x^{(i)}, y^{(i)})_{1 \leq i \leq m}$  إلى معطيات التدريب. حيث  $m$  عدد معطيات التدريب. ويكون المثال التدريبي رقم  $i$ ، له الصف  $y^{(i)}$ . مع كون  $y^{(i)} = +1$  في حال الصف الأول، و  $y^{(i)} = -1$  في حال الصف الثاني. وإن  $x^{(i)}$  هو شعاع عددي بـ  $n + 1$  بُعد أي  $x^{(i)} \in \mathbb{R}^{n+1}$ . وهو ما سميناه شعاع الميزات في الفقرة 2.1.2. أي هنا لدينا  $n$  ميزة، حيث لتبسيط العلاقات الرياضية نضيف  $x_0^{(i)} = 1$ .

النموذج المطروح في خوارزمية ال SVM، هو تعريف تابع  $f: \mathbb{R}^{n+1} \rightarrow \{-1, +1\}$ . حيث أننا نقول أنه لأجل عينة ما  $(x, y)$ ، فإنها تنتمي إلى الصف الأول في حال كان  $f(x) \geq 0$ ، وتنتمي إلى الصف الثاني في

حال  $f(x) < 0$ . سنأخذ مبدئياً للتبسيط التابع  $f$  بالشكل  $f(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$  حيث  $\theta = (\theta_j)_{0 \leq j \leq n}$  هي البارامترات التي يمكن تغييرها.


مسألة الأمثلة التي نريد حلها هي:

$$\operatorname{argmin}_{\theta \in \mathbb{R}^{n+1}} \left( \|\theta\|_2^2 + C \cdot \sum_{i=1}^m [1 - y^{(i)} f(x^{(i)})]_+ \right) \quad (1)$$

where  $f(x^{(i)}) = \sum_{j=0}^n \theta_j x_j^{(i)}$

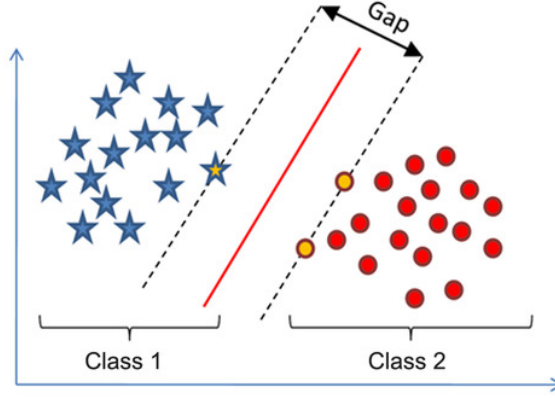
حيث أن التابع  $[\cdot]_+ = \max(z, 0)$  هو تابع الجزء الموجب؛ أي  $\|z\|_+ = \max(z, 0)$  و  $\|\cdot\|_2$  هو التنظيم الإقليدي؛ أي  $\|\theta\|_2^2 = \sum_{j=0}^n \theta_j^2$ . والبارامتر  $C$  هو معامل وزن، يحدد مدى التفضيل والمساومة بين الحدين الأول والثاني في المعادلة. وهو بارامتر فوق Hyperparameter أي يجب تحديده قبل البدء بحل مسألة الأمثلة، وإن تغييره يغير حل المسألة.

إن الحد الأول  $\|\theta\|_2^2$  في المعادلة 1 هو للتنظيم Regularization. هذا الحد يضبط قيم البارامتر  $\theta$  ويمنعها من أن تأخذ قيم كبيرة. الحد الثاني يمثل مجموع قيمة الخطأ الحاصل في كل مثال تدريبي من معطيات التدريب. حيث أن الخطأ الحاصل في عينة ما  $(x, y)$  هو  $[1 - y \cdot f(x)]_+$ . يمكن تأمل صفات هذا الخطأ من خلال الشكل 1.2. حيث نلاحظ مثلاً في حالة  $y = 1$  أن الخطأ يساوي الصفر عندما  $f(x) \geq 1$  وأنه يتزايد بشكل خطي كلما أبتعدت قيمة  $f(x)$  عن 1 بالاتجاه الخاطئ.




الشكل 1.2: الخطأ في العينة الواحدة في نموذج الـ SVM.

يمكن البرهان على أنه في حالة كون المعطيات قابلة للفصل بخط مستقيم، فإن حل مسألة الأمثلة سيعطي المستقيم  $f$  الذي يحقق أكبر هامش ممكن؛ أي إذا قمنا بحساب البعد بين كل نقطة وهذا المستقيم، فإن أصغر بعد سيكون أكبر ما يمكن، وهذا ما يوضحه الشكل 2.2.



الشكل 2.2: مستقيم يفصل صفتين بهامش أعظمي.

ولكن أيضاً يمكننا اختيار تابع غير خطي. هذا مفيد مثلاً في حال كان شكل معطيات التدريب مثلما في الشكل 3.2. إذ يوجد أسلوب يسمى بال Kernel Trick، يسمح لنا بفعل هذا. ينص هذا الأسلوب على



الشكل 3.2: معطيات التدريب غير قابلة للفصل باستخدام مستقيم.

تعريف  $f$  بالشكل  $f(x) = \sum_{i=1}^m \theta_i K(x, x^{(i)}) + \theta_0$ ، ثم حل مسألة الأمثلة السابقة ذاتها. نلاحظ هنا أنه لدينا  $m + 1$  بارامتر عوض الـ  $n + 1$  بارامتر في الحالة السابقة. و يسمى التابع  $K$  بالنواة Kernel. فمثلاً اختيار  $K(u, v) = \sum_{j=1}^n u_j v_j$  يؤدي إلى حل مكافئ لحل المسألة الموضحة في المعادلة 1. تسمى هذه النواة بالنواة الخطية Linear Kernel.

إن أشهر النوى المستخدمة عادةً هي:

$K(u, v) = u^T v$	Linear Kernel	النواة الخطية
$K(u, v) = (u^T v + r)^d$	Polynomial Kernel	النواة الحدودية
$K(u, v) = \exp(-\gamma \ u - v\ _2^2)$	Gaussian Kernel	النواة الغاوسية

إذ أن الرمز  $u^T$  يرمز إلى المتقول وتحديدًا فإن  $u^T = (u_1, \dots, u_n)$  تسمى النواة الغاوسية أيضاً بـ Radial Basis Function (RBF) Kernel. وننوه أن البارامترات المذكورة  $r, d, \gamma$  هي بارامترات فوقية.

حل مسألة الأمثلة المطروحة، توجد العديد من الخوارزميات. هذا النوع من المسائل، ومسائل الأمثلة بشكل عام هو فرع مدروس بشكل جيد في الرياضيات تحت اسم Mathematical Optimization. فتوجد العديد من الخوارزميات المستخدمة لحل مسألة الأمثلة المطروحة. من أشهرها هي خوارزمية Sequential Minimal Optimization (SMO). يتطلب شرحها الخوض في كثير من التفاصيل الرياضية وهو خارج نطاق هذا المشروع.

آخر ما يجب ذكره، هو الأسلوب المستخدم للتصنيف في حال وجود أكثر من صنفين. هذا الأسلوب مستخدم بشكل عام ويسمى بـ One-versus-All multi-class classification. الفكرة كالتالي، لأجل كل صف، نعتبر جميع الصفوف الأخرى هي صف آخر. ونبني لكل صف، مُصنّف على هذا الأساس. الآن لأجل دخل جديد، نحسب  $f$  لكل مُصنّف، ونأخذ الصف الذي يحقق أكبر قيمة.

## 4.1.2 معايير التقييم

تختلف معايير تقييم صحة نماذج تعلم الآلة باختلاف نوع المسائل التي تقوم بحلها. سنتحدث في هذه الفقرة عن أهم معايير التقييم المستخدمة في مسائل التصنيف.

بدايةً لنضع بعض الرموز لتبسيط العلاقات الرياضية وتوضيح الأفكار. كما تحدثنا سابقاً عن معطيات التدريب، من المعتاد أن توجد معطيات أخرى مستقلة عن معطيات التدريب تسمى بمعطيات الاختبار Test Set. حيث أنه بعد الحصول على النموذج الناتج من خوارزمية تعلم الآلة بتدريبه على معطيات التدريب، يتم اختبار هذا النموذج على معطيات الاختبار. سنرمز لها بـ TS. سنرمز لمجموعة عناصرها بـ  $(x_i, y_i)$ ، حيث  $x_i$  هو شعاع الميزات،  $y_i$  هو الصف الموافق. وسنرمز بـ  $\hat{y}_i$  للصف الذي تنبأت به خوارزمية تعلم الآلة المستخدمة والتي نريد تقييمها. وسنستخدم الرمز  $| \cdot |$  لعدد عناصر مجموعة ما. فمثلاً إن  $|y_i = c|$  هو عدد العناصر من TS التي لها الصف  $c$ .

الصحة Accuracy هي المعيار الأشهر. فهي نسبة العينات التي تم تصنيفها بشكل صحيح. أي:

$$\text{Accuracy} = \frac{|\hat{y}_i = y_i|}{|\text{TS}|}$$

إنّ هذا المعيار غير كافٍ للتعبير عن مدى قوة النموذج الناتج. لتأمل مثال تكون فيه معطيات التدريب فيها صنفين فقط. نسبة ورود الصف الأول هو 1%، مثل حالة تشخيص مرض نادر. فبإمكاننا بسهولة الحصول على نموذج بدقة 99%. هذا النموذج يتنبأ دائماً بالصف الثاني؛ فلكون ورود عينات تنتمي للصف الأول نادر جداً تكون صحة هذا النموذج عالية. ولكن من الواضح أن هذا النموذج غير مجدي. النقاش السابق يدفع لتحديد معايير أخرى للتقييم.

الدقة Precision هي معيار يعبر عن دقة تصنيف صف معيّن. دقة تصنيف الصف  $c$  هي نسبة العينات التي صنفت بشكل صحيح في الصف  $c$  من بين جميع العينات التي صنفت بالصف  $c$ . أي:

$$\text{Precision for class } c = \frac{|\hat{y}_i = c \wedge y_i = c|}{|\hat{y}_i = c|}$$

الإرجاع Recall هو معيار يعبر عن مدى استرجاعنا لعينات من صف معيّن. معيار الإرجاع للصف  $c$  هو نسبة العينات التي صنفت بشكل صحيح في الصف  $c$  من بين جميع العينات التي هي ضمن الصف  $c$  فعلاً. أي:

$$\text{Recall for class } c = \frac{|\hat{y}_i = c \wedge y_i = c|}{|y_i = c|}$$

المعيار الأخير الذي سنتحدث عنه يسمى بـ F1-score. ينتج من حاجتنا إلى الاعتماد على قيمة عددية واحدة فقط لمقارنة نموذجين معاً. وهو معيار يجمع بين الدقة والإرجاع. النموذج المقترح للجمع بينهما هو:

$$\text{F1 - score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

سنرمز لهذا المعيار اختصاراً بـ F-score. حيث أن الرقم 1 في اسمه يدل على أننا نعطي للدقة والإرجاع نفس الأهمية. فهذا المعيار حالة خاصة من معيار أعم يسمح بإعطاء أهمية أكبر للدقة على الإرجاع وبالعكس، ولكن لن نتحدث عنه.

## 2.2 معالجة اللغات الطبيعية

معالجة اللغات الطبيعية (Natural Language Processing (NLP هو المجال الذي يدرس الآليات التي تسمح للحواسيب والآلات بفهم ومعالجة اللغات الطبيعية مثل اللغة العربية والإنكليزية وغيرها [26]. ويعتبر مجال مهم في الذكاء الصناعي. يتقاطع هذا المجال مع العديد من المجالات منها علم اللسانيات وتعلم الآلة وغيرها. سنتحدث في هذه الفقرة بشكل بسيط عن أهم المراحل في معالجة اللغات الطبيعية.

- التحليل الصرفي Morphological Analysis وهو المرحلة التي يجري فيها تحليل الكلمة إلى مكوناتها الأساسية. يُنفذ هذا التحليل على مستوى الكلمة دون النظر إلى السياق. بشكل أساسي هناك مرحلتين لهذا التحليل. التقطيع Tokenization والتشذيب Stemming.

خرج مرحلة التقطيع هو الرموز التي تكون الجملة Tokens. أي مثلاً إنّ الجملة  
Google inc. is huge.

سيتم تقسيمها إلى خمس رموز وهي:

{ Google | inc. | is | huge | . }

لاحظ أن النقطة الأخيرة تعتبر رمز منفصل بينما النقطة في الكلمة inc. ليست رمز منفصل.

خرج مرحلة التشذيب هو جذر الكلمة، بالإضافة إلى السوابق واللواحق، ومعلومات أخرى تختلف باختلاف اللغة. مثلاً إن جذر الكلمات fish, fishing, fished, fisher هو fish. واللواحق هي ing, ed, er على الترتيب.

- تحديد أنماط الكلمات Part-of-Speech Tagging وهو عملية إسناد الأنماط النحوية الملائمة لكل كلمة من كلمات الجملة. دخل هذه المرحلة عادةً يكون كلمة ضمن سياق محدد (ضمن جملة). الخرج الناتج يكون النمط النحوي لهذه الكلمة (اسم، فعل، صفة، إلخ).


- التكتيل Chunking وهو تقسيم الجملة إلى عبارات أصغر؛ أي عبارات اسمية، أو عبارات فعلية، إلخ. يوضح الشكل 4.2 مثال على ذلك.

[NP He ] [VP reckons ] [NP the current account deficit ] [VP will  
narrow ] [PP to ] [NP only # 1.8 billion ] [PP in ] [NP September ]

الشكل 4.2: عملية التكتيل للجملة He reckons the current account deficit will narrow to only # 1.8 billion in September. وجملة اسمية (NP) Noun Phrase، وعبارات جر (PP) Prepositional Phrase.




- الشجرة النحوية Parsing Tree. في الواقع يمكن اعتبار الشجرة النحوية الخرج الناتج عن العمليات السابقة مجتمعة. حيث يتم تمثيل الجملة كشجرة. انظر الشكل 5.2 لمثال توضيحي. الاختصارات المكتوبة، مثل NN تعني اسم مفرد singular noun، NNS تعني اسم جمع plural noun. وللإطلاع على هذه القائمة كاملةً انظر [1].



الشكل 5.2: الشجرة النحوية الناتجة للجملة The children ate the cake with a spoon.

- تحليل التبعية Dependency Parsing. نظراً لقصور الشجرة النحوية عن إعطاء كامل المعلومات حول الجملة المدروسة، تم اقتراح تمثيل المعلومات النحوية على شكل بيان التبعية Dependency Graph. يوضح هذا البيان العلاقات النحوية بين كلمات الجملة. إذ يتكون من عقد تمثل الكلمات ووصلات تحدد العلاقة بين هذه الكلمات. يبين الشكل 6.2 مثلاً على خرج تحليل التبعية. الاختصارات المكتوبة للعقد هي ذاتها المستخدمة في حالة الشجرة النحوية. الاختصارات المكتوبة للوصلات، مثل det تربط بين الاسم وأداة التعريف المرتبطة به، nsubj تربط بين الفعل والفاعل. وللإطلاع على هذه القائمة كاملةً انظر [7].



الشكل 6.2: بيان التبعية الناتج للجملة A member of the sales department can then reject or accept the order.

- حل الغموض في حالات الإحالة Anaphora Resolution. الإحالة Anaphora هي استخدام

ضمائر أو تعابير للإشارة إلى اسم أو تعبير تم ذكره في سياق سابق في النص. فإذا تأملنا المثال التالي:

**They** buy the issue, then resell it to the public.

إن *it* تشير إلى *issue*. وفي هذه الحالة يكون المشار إليه واقعاً في نفس الجملة. أمّا في حالة *They* فيكون المشار إليه واقعاً في جملة سابقة.

## 3.2 الأوراق العلمية

كما شرحنا في الفقرة 1.2 وتحديدًا الفقرة 2.1.2، إن أولى الخطوات اللازمة لتنفيذ أي نظام يستخدم تعلم الآلة هي تحديد الميزات التي سيتم استخدامها. فهذا المشروع يتعامل مع النصوص وكون المسألة المطروحة هي تقييم جودة هذه النصوص من ناحية سهولة القراءة، فمن المهم جداً معرفة الميزات التي ستعبر عن وتوصف جودة نص.

بالعودة إلى العديد من الأوراق العلمية التي تتقاطع مع هذا المشروع، تم تجميع عدد من الأفكار والمنهجيات التي تم تبنيها والاعتماد عليها كإطار عمل ضمن المشروع. سنذكر في هذه الفقرة أهم الأوراق العلمية التي تمت دراستها، وأهم الأفكار والمنهجيات المتبعة فيها. بالإضافة إلى الميزات وخوارزميات تعلم الآلة المستخدمة لحل مسائل مشابهة للمسألة المطروحة في هذا المشروع.

إن فكرة تقييم النصوص من ناحية صعوبة القراءة بشكل موضوعي (غير شخصي) بدأت تقريباً منذ قرن. الأفكار الأولية التي واجهت هذا الموضوع هي عبارة عن علاقات رياضية بسيطة. ولقد اعتمدت على خصائص سطحية في النص المدروس. مثل متوسط طول الجملة، ومتوسط طول الكلمة. فمثلاً إن Flesch Score يعطى بالعلاقة

$$\text{Flesch Score} = 206.835 - 1.015 \cdot \frac{\# \text{words}}{\# \text{sentences}} - 84.6 \cdot \frac{\# \text{syllables}}{\# \text{words}}$$

أي يمثل علاقة خطية لمتوسط طول الجملة بالكلمات، ومتوسط طول الكلمة بالمقاطع الصوتية. وكلما كان هذا المقدار أكبر، كلما كان النص أسهل للقراءة. في [5] أجري مقارنات بين عدد واسع من هذه العلاقات. وفي [6] تم رسم ودراسة توزيع عدد من هذه المعايير على عدد كبير من النصوص. على الرغم من كون هذه العلاقات تبدو سطحية من ناحية التمثيل اللغوي للنص، تم اعتمادها بشكل واسع لمدة من الزمن.

كما ظهرت نماذج أكثر تعقيداً تعتمد على مفهوم ال-n-gram. وهو نموذج إحصائي لتمثيل اللغة؛ يعبر عن احتمال ورود كلمة ضمن سياق معين، أو احتمال ورود جملة أو سياق معين. وهو تمثيل بسيط للانترورية في

اللغة الانكليزية. استخدم هذا المفهوم بالإضافة إلى ميزات أخرى بُنيت فوقه ومستوحاة من مفهوم الانتروبية في عدد من الدراسات أهمها [9,3]. وكانت النتائج أفضل بشكل واضح عن نتائج المعايير السابقة والمعتمدة على علاقات رياضية بسيطة. حيث تم الاعتماد على خوارزميات تعلم الآلة. الخوارزمية الأكثر استخداماً والتي حققت أفضل النتائج كانت الـ SVM.

مع تطور الأدوات في معالجة اللغات الطبيعية، أصبح من الممكن أن نأخذ بعين الاعتبار مؤشرات أقوى، مفرداتية ونحوية وغيرها. في [11,10] تمت دراسة ومقارنة العديد من الميزات التي تعتمد بشكل أساسي على تقدم الأدوات في معالجة اللغات الطبيعية. حيث تمت مقارنة عدّة ميزات، وبعدها أنواع. مثل التنوع في الأفعال، والكلمات المستخدمة، وكثافة الأسماء المستخدمة في النص. بالإضافة إلى الترابط بين الجمل باستخدام بيان التبعية والعديد غيرها. أفضل نتيجة تم تحقيقها كانت باستخدام الـ SVM على مجموعة جزئية من الميزات المدروسة.

أيضاً لقد تمت دراسة تعقيد النصوص المكتوبة من قبل الطلاب الذين يتعلمون اللغة الانكليزية. تم ذلك تحت ما يسمى أبحاث تعلم اللغات second language acquisition. حيث تمت دراسة عدد من المؤشرات التي تعبر عن تعقيد النص، بما يفيد في دراسة تحسن الطلاب أثناء تعلمهم للغة. كما أن دراسات لاحقة قامت بأكملت آليات حساب هذه المؤشرات أهمها [12]. فكان تغيير هذه المؤشرات مع الزمن، يبيّن مستوى تحسن الطلاب في تعلم اللغة. وكان أول استخدام لهذه الدراسات لبناء نموذج تعلم آلة لتقييم جودة النصوص هو في [15]. حيث تم الاعتماد على ميزات مستوحاة بشكل مباشر من هذه المؤشرات. معظم هذه الميزات تعبر عن تعقيد تراكيب الجمل. مثل وجود جمل شرطية أو جمل معطوفة على بعضها وهكذا.

أيضاً تم استخدام ميزات تعبر عن نسبة ورود كلمات معينة ضمن النص. فإن ورود كلمات متقدمة ضمن النص وبتواتر عالي قد يكون مؤشر جيد على كون النص بمستوى متقدم. هذه الكلمات تكون غالباً منتقاة من مصدر تعليمي. فقد تم استخدام كلمات من المصدر<sup>1</sup> The Academic Word List في [27,18,15]. و تم استخدام كلمات من المصدر<sup>2</sup> English Vocabulary Profile في [24]. حيث تبين أن لهذه الميزات دور جيد في تحسين أداء النماذج الناتجة.

سنوضح لاحقاً وبتفصيل أكبر في الفقرة 4.3 الميزات المستخدمة في هذا المشروع. يجب أيضاً التنويه إلى المعطيات المستخدمة في هذه الدراسات. إن معظم المعطيات هي من مصدر تعليمي، مثل مجلات تعليمية للأطفال حيث أن المقالات مصنفة بحسب الفئة العمرية المناسبة. سنتحدث لاحقاً في الفقرة 3.3 عن مجموعة المعطيات المستخدمة في هذا المشروع وخصائصها.

<sup>1</sup> للإطلاع على هذه القائمة كاملةً انظر [2].

<sup>2</sup> لمزيد من التفاصيل انظر <http://www.englishprofile.org>

## الفصل الثالث

# تصميم النظام

يبيّن هذا الفصل منهجية العمل المتبعة خلال تنفيذ المشروع. ويشرح النظام على مستوى عالي من التجريد وفق مخططات صندوقية. كما يسرد الميزات التي استخرجها من النصوص. ويسرد خوارزميات تعلم الآلة التي تم استخدامها.

### 1.3 منهجية العمل

نتعامل مع المسألة المطروحة ضمن المشروع على أنها مسألة تصنيف مقروئية نص مكتوب باللغة الانكليزية وفق عدّة مستويات. فالغاية المرجوة هي معرفة مستوى صعوبة نص معيّن وإلى أي مستوى ينتمي. سؤال قد يتم طرحه هنا وهو: ما هو عدد المستويات وما هو التفاوت ومعيار المقارنة بينها؟ الإجابة هي أن عدد المستويات والفروقات بينها يتم تحديده ضمن المعطيات التي ستستخدم لتدريب المصنّف. فقد تكون هذه المعطيات مفصولة إلى أي عدد من المستويات. ولكن وجب أن يكون معيار المقارنة بين هذه المستويات هو مقروئية النصوص وذلك لكي يحقق التطبيق الناتج الهدف المرجو منه.

تبدأ أنظمة تعلم الآلة عادة بجمع المعطيات. في حالتنا هذه، نريد جميع عدد كبير من النصوص المصنّفة بشكل مسبق وصحيح إلى مستوى صعوبة مقروئيتها. لم نحتاج إلى القيام بهذه المرحلة ضمن المشروع بسبب توافر هكذا معطيات. المرحلة التي تليها هي مرحلة استخراج الميزات. إذ يتم التعبير عن المعطيات الخام بأشعة من الميزات يمكن لخوارزميات تعلم الآلة إجراء عمليات حسابية عليها. وبعد استخراج الميزات، يتم اختيار خوارزمية تعلم

الآلة المناسبة وضبط برامتها لتدريبها على جزء من هذه المعطيات (معطيات التدريب) واختبارها على الجزء الآخر (معطيات الاختبار). وذلك لتقييم مستوى أدائها ومعرفة الجدوى من استخدامها.

أخيراً بعد إجراء عملية التدريب والحصول على مُصنّف جاهز للاستخدام، نقوم لأجل نص جديد باستخراج ميزات واستخدام المصنّف للحصول على مستوى مقروئية هذا النص.

## 2.3 المخططات الصندوقية للنظام

كما رأينا في الفقرة السابقة، توجد عدّة مراحل لتنجز النظام بشكل كامل. ودون الخوض في كثير من التفاصيل، سنعتبر أنه توجد مرحلتان أساسيتان لتنجز المشروع. الأولى هي للحصول على مُصنّف جاهز للاستخدام. الثانية هي استخدام هذا المصنّف.

يبيّن الشكل 1.3 المخطط الصندوقي للنظام الذي تم تنجيزه للحصول على المصنّف وتقييم أدائه. بينما يبيّن الشكل 2.3 المخطط الصندوقي لاستخدام هذا المصنّف.

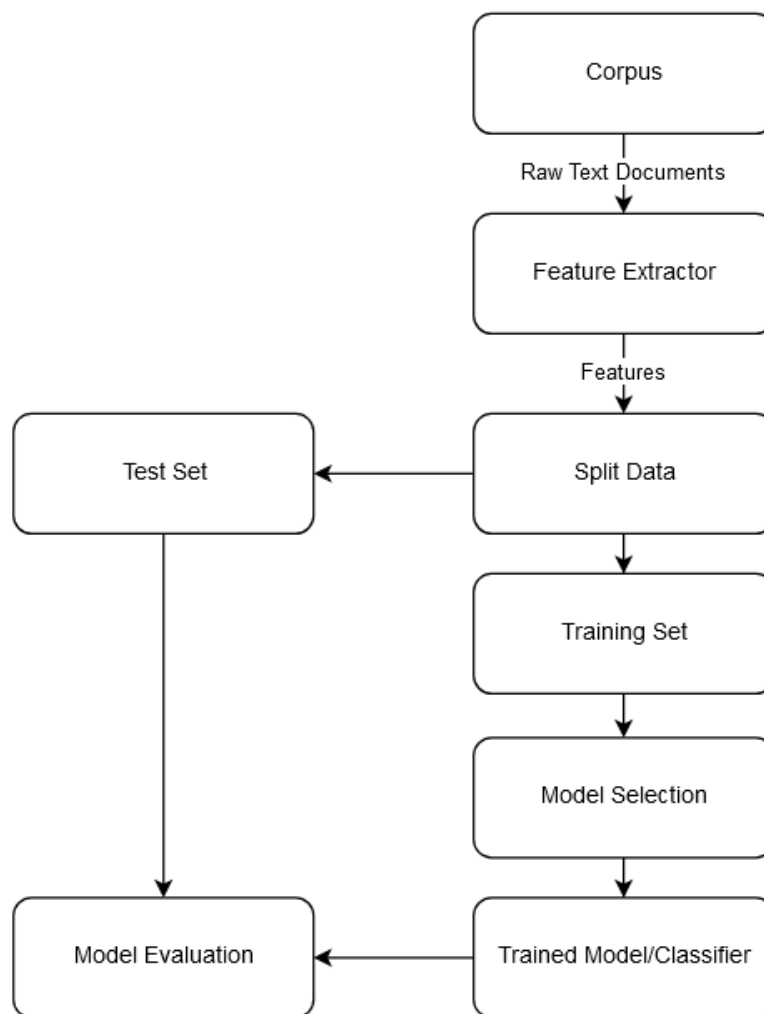
## 3.3 المعطيات المستخدمة

تبيّن هذه الفقرة المعطيات المستخدمة ضمن المشروع وخصائصها.


### 1.3.3 One Stop English Corpus (OSE)

يعود الفضل في تجميع هذه المعطيات إلى [27]. تم تجميع هذه المعطيات من الموقع <http://www.onestopenglish.com> في الفترة ما بين 2016 – 2013. وهو موقع تعليمي بأكثر من 700,000 مستخدم من 100 دولة.

أحد ميزات هذا الموقع هو وجود درس تعليمي أسبوعي له طابع إخباري يحوي مقالات من الصحيفة البريطانية The Guardian. إذ تتم إعادة صياغة مقالات هذه الصحيفة من قبل المدرسين لتناسب ثلاثة مستويات من الطلاب (مبتدأ elementary، متوسط intermediate، متقدم advanced). أي أنه تتم إعادة صياغة



الشكل 1.3: المخطط الصندوقي للحصول على المصنّف وتقييم أدائه.



الشكل 2.3: المخطط الصندوقي لاستخدام المصنّف.

محتوى الصحيفة الأصلي إلى ثلاث نسخ متدرجة الصعوبة من حيث مقروئيتها مع المحافظة على أكبر قدر من فحوى المحتوى الأصلي. يبين الجدول 1.3 عينة من هذه المعطيات.

تُبين لنا طريقة جمع هذه المعطيات أهميتها بالنسبة للمشروع. إذ إن معيار المقارنة بين هذه المستويات هو مقروئية النصوص من ناحية تعقيد تراكيب الجمل أو بساطتها وذلك لنصوص لها نفس الفحوى. وإجراء الاختبارات عليها سيوضح الجدوى من استخدام هذا النظام في تحليل مقروئية النصوص من ناحية الصياغة.

Reading Level	Sample Text
Elementary	To tourists, Amsterdam still seems very liberal. Recently the city's Mayor told them that the coffee shops that sell marijuana would stay open, although there is a new national law to stop drug tourism. But the Dutch capital has a plan to send antisocial neighbours to scum villages made from shipping containers, and so maybe now people wont think it is a liberal city any more.
Intermediate	To tourists, Amsterdam still seems very liberal. Recently the city's Mayor assured them that the city's marijuana-selling coffee shops would stay open despite a new national law to prevent drug tourism. But the Dutch capitals plans to send nuisance neighbours to scum villages made from shipping containers may damage its reputation for tolerance.
Advanced	Amsterdam still looks liberal to tourists, who were recently assured by the Labour Mayor that the city's marijuana-selling coffee shops would stay open despite a new national law tackling drug tourism. But the Dutch capital may lose its reputation for tolerance over plans to dispatch nuisance neighbours to scum villages made from shipping containers.

جدول 1.3: عينة من جمل ال OSE المصنفة إلى ثلاثة مستويات.

تتألف هذه المعطيات من 567 نص موزعين بالتساوي إلى المستويات الثلاثة، أي يوجد 189 نص في كل مستوى. ويبين الجدول 2.3 بعض الإحصائيات الوصفية لنصوص هذه المعطيات. وهي متوسط طول النص، والانحراف المعياري لطول النص وذلك للمستويات الثلاثة كلاً على حدا. وإن الواحدة المستخدمة لطول النص هي الكلمة. نلاحظ (كما هو متوقع) أن الطول الوسطي للنصوص يتزايد مع تزايد المستوى. وأن الانحراف المعياري لطول النصوص كبير مما يجعل طول النص معيار غير كافٍ لتحديد صعوبته.

هذه النصوص متاحة على الرابط <https://github.com/nishkalavallabhi/OneStopEnglishCorpus> ويجب التنويه إلى أن هذه المعطيات لم تستخدم كما هي، بل تم إجراء تنضيف شبه يدوي عليها. حيث أنه

Reading Level	Avg. Num. Words	Std. Dev.
Elementary	533.17	103.79
Intermediate	676.59	117.15
Advanced	820.49	162.52

جدول 2.3: إحصائيات وصفية لنصوص ال OSE.

وُجِدَت مجموعة من المحارف الغريبة التي تم استبدالها بمحارف مناسبة بحسب سياق ورودها ضمن النصوص. فقد سبب بعض هذه المحارف مشاكل في قراءة النص أو استخدام مكتبات معالجة اللغات الطبيعية. بالإضافة إلى كونها تشكل تشويش في المعطيات. فيمكن اعتبار أن أحد منجزات هذا المشروع هو تنظيف معطيات ال OSE بالكامل وبإشراف شبه يدوي.

### 4.3 الميزات المستخدمة

### 5.3 الخوارزميات المستخدمة



## الفصل الرابع


# التصميم البرمجي والتنجز

نبيّن في هذا الفصل التصميم البرمجي للنظام وطريقة تنجيذه والأدوات المستخدمة لذلك. ونقوم بشرح مخططات الصفوف للحزم البرمجية. وسرد القرارات التصميمية المعتبرة والأنماط التصميمية Design Patterns المستخدمة. ننوه إلى أن الكود البرمجي وجميع الحزم البرمجية موجودة تحت المجلد `src`. `todo`

### 1.4 قراءة المعطيات

تم بناء الحزمة `datasets` للتعامل مع المعطيات. أي لقراءة النصوص وكتابة الميزات. تحوي هذه الحزمة صف وحيد `Document` وهو الصف الأساسي المستخدم ليحمل معلومات النص مثل اسمه ومساره وغيرها. يبيّن الشكل 1.4 مخطط الصفوف لهذه الحزمة. كما تحوي هذه الحزمة حزمتين جزئيتين هما الحزمة `corpora` والحزمة `writers`.

الحزمة `corpora` فيها مجموعة من الصفوف المستخدمة لقراءة مجموعة كبيرة من النصوص والمرور عليها ومعالجتها. إذ أن الصفوف خارج هذه الحزمة تستخدم الواجهة `TextCorpus`. ويمكن توسيع هذه الحزمة بإنشاء صف جديد ينجّز هذه الواجهة. حيث يجب أن يعرف آلية الحصول على النصوص المكتوبة وتصنيفاتها. تم استخدام النمط التصميم `Iterator design pattern` لتحقيق ذلك. إذ وجدناه مناسباً ويقوم بتأدية الغرض اللازم. يبيّن الشكل 2.4 مخطط الصفوف لهذه الحزمة.




الشكل 1.4: مخطط الصفوف للحزمة datasets.

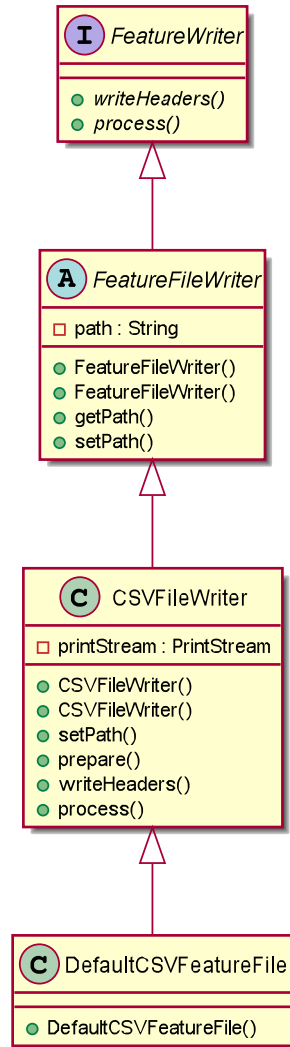
وتم بناء الحزمة writers لكتابة ملف فيه الميزات التي تم استخراجها من هذه النصوص. يبين الشكل 3.4 مخطط الصفوف لهذه الحزمة. الواجهة الأساسية الذي يتم استخدامها خارج هذه الحزمة هي FeatureWriter. الصف المكتوب والذي ينجزها يقوم بكتابة الميزات على ملف بلاحقة (Comma Separated Values). CSV. يمكن بإضافة صف ينجز هذه الواجهة تعريف آلية لكتابة الميزات بأي لاحقة أخرى بحسب المطلوب كـ XML مثلاً.

## 2.4 استخراج الميزات

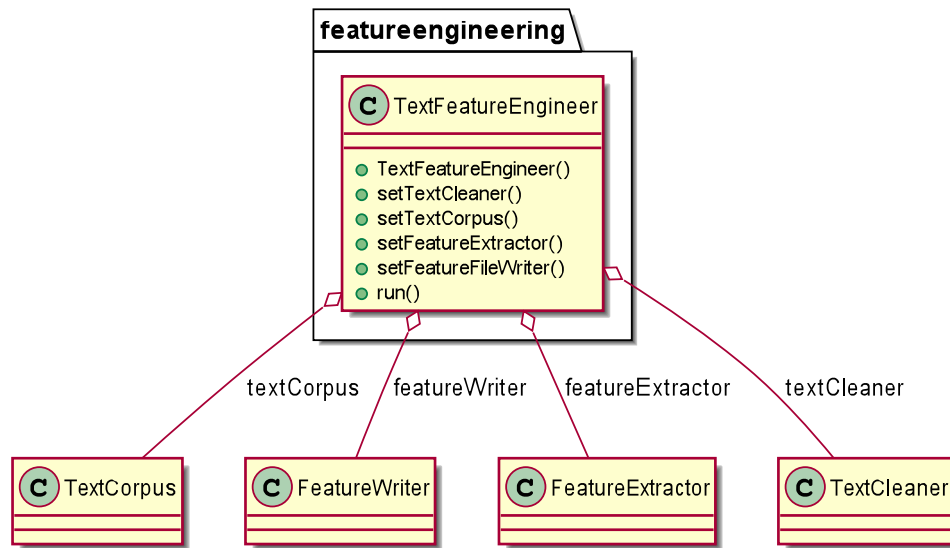
تم بناء الحزمة featureengineering لتحتوي الصفوف المسؤولة عن استخراج الميزات من النصوص. تحتوي هذه الحزمة صف واحد وأربع حزم جزئية. الصف الموجود TextFeatureEngineer هو صلة وصل، إذ يقوم باستخدام الصف اللازم لقراءة النصوص واستخراج الميزات منها ثم كتابة ملف الميزات. وأثناء عمله يقوم بطباعة معلومات مفيدة. مثل اسم وقم الملف الذي تتم معالجته حالياً. وبعد الانتهاء يذكر عدد الملفات الذي حدث خطأ أثناء معالجتها. ننوه إلى أن تنفيذ عملية استخراج الميزات تستهلك وقت يتراوح بين ساعة وساعتين. والسبب الأساسي في استهلاك هذا الوقت الكبير هو استخدام مكتبات معالجة اللغات الطبيعية. يوضح الشكل 4.4 مخطط الصفوف لهذه الحزمة.



الشكل 2.4: مخطط الصفوف للحزمة datasets.corpora



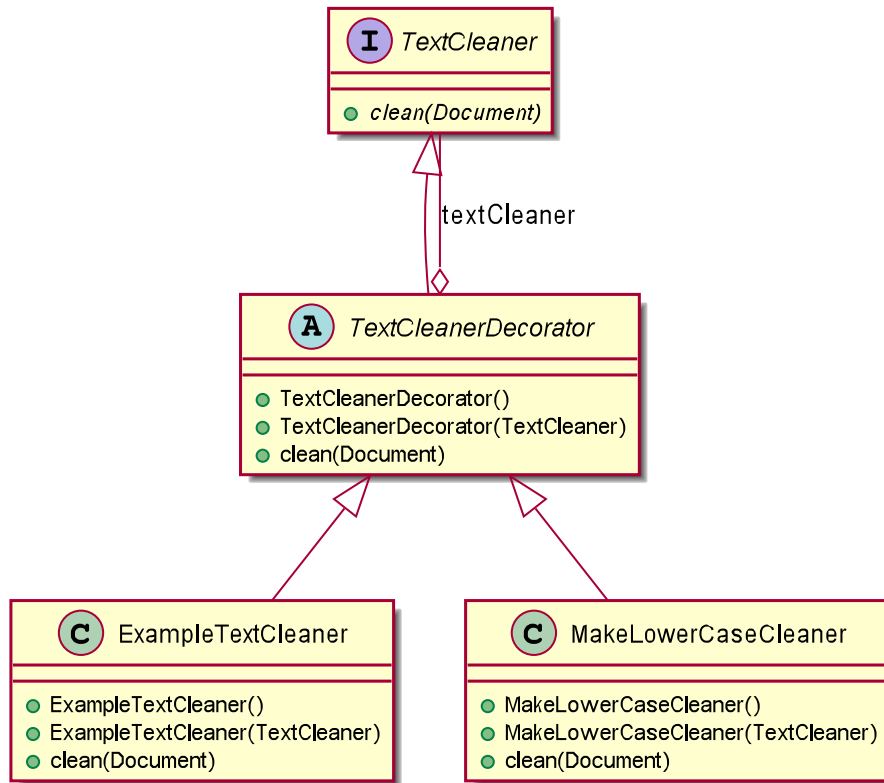
الشكل 3.4: مخطط الصفوف للحزمة datasets.writers



الشكل 4.4: مخطط الصفوف للحزمة featureengineering.

## 1.2.4 الحزمة cleaners

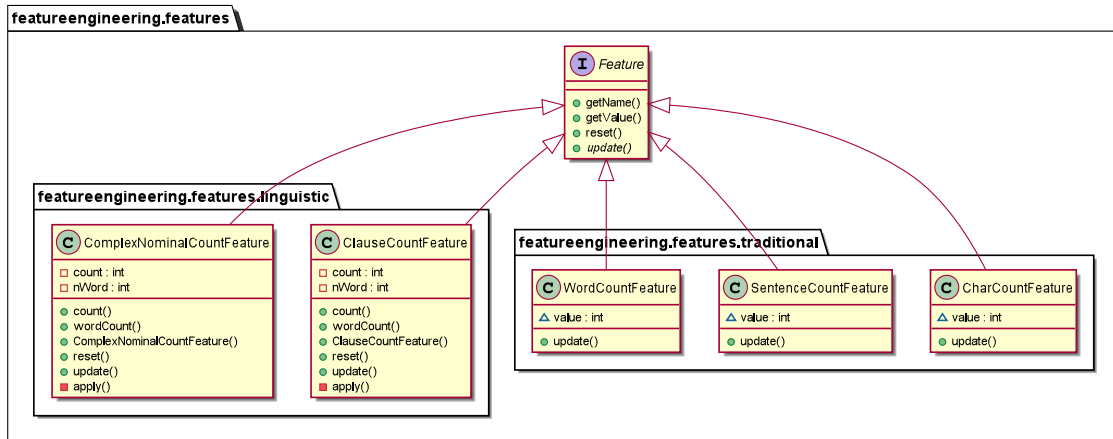
تحتوي هذه الحزمة على الصفوف التي تقوم بتنظيف النص بشكل آلي قبل البدء بعملية استخراج الميزات. مثل أن يتم تحويل جميع الأحرف إلى حروف صغيرة، أو حذف علامات الترقيم، إلخ. تم استخدام النمط التصميمي Decorator design pattern. وذلك للسماح باستخدام عدد من الصفوف التي تقوم بالتنظيف دون تحديد عددها وبشكل سهل الاستخدام. يبين الشكل 5.4 مخطط الصفوف لهذه الحزمة.



الشكل 5.4: مخطط الصفوف للحزمة featureengineering.cleaners.

## 2.2.4 الحزمة features

تحتوي هذه الحزمة على الميزات التي تم تنجيزها. كل صف يمثل ميزة. وجميع هذه الصفوف تنجز الواجهة Feature. ويمكن بإنشاء صفوف جديدة تُنجز هذه الواجهة إضافة ميزات جديدة وتوسيع الحزمة. يبين الشكل 6.4 جزء من مخطط الصفوف لهذه الحزمة. نلاحظ أنه تم تقسيم الميزات بحسب نوعها إلى عدة حزم جزئية.



الشكل 6.4: عيّنة من مخطط الصفوف للحزمة featureengineering.features.


### 3.2.4 الحزمة featuresets

كل صف من صفوف هذه الحزمة يمثل مجموعة ميزات مترابطة. يبين الشكل 7.4 عيّنة جزئية من مخطط الصفوف لهذه الحزمة. الهدف من هذه الصفوف هو تسهيل استخدام الميزات التي تم تنجيزها ضمن سياق آخر. يمكن للمستخدم (المستخدم في هذه الحالة هو مبرمج) بإنشاء صف يُنجز الواجهة FeatureSet واستخدام الميزات التي يريد من الحزمة features. أيضاً وجود هذه الصفوف يسمح بتركيب عدد من الميزات؛ فمثلاً يمكن استخدام الصف WordCountFeature لحساب عدد الكلمات ضمن النص، واستخدام الصف SentenceCountFeature لحساب عدد الجمل، ثم حساب متوسط طول الجملة بتقسيم عدد الكلمات على عدد الجمل. تم استخدام هذا التصميم لفصل الميزات عن بعضها بحيث تكون مستقلة ويمكن استخدام كل منها على حدة، وأيضاً لتفادي إعادة الحسابات ورفع الكفاءة.

### 4.2.4 الحزمة extractors

يبين الشكل 8.4 مخطط الصفوف لهذه الحزمة. المكون الأساسي في هذه الحزمة هي الواجهة FeatureExtractor. إذ يعتبر المكون الأساسي في عملية استخراج الميزات. له التابعين ()getFeatureList الذي يعيد أسماء الميزات. والتابع ()extract(String) الذي يعيد قيمة الميزات التي تم استخراجها للنص. يمكن تنجيز هذه الواجهة بعدة طرق.

الصف الذي تم إنشائه لتنجيز هذه الواجهة يستخدم النمط Observer design pattern. وهو الصف



الشكل 7.4: عينة من مخطط الصفوف للحزمة featureengineering.featuresets.

ObservableFeatureExtractor. يحوي هذا الصف على مجموعة من الـ FeatureSet كل منها هو Observer. تم استخدام هذا النمط لتصميم هذا الصف لكون عملية إعراب النص parsing باستخدام مكتبة معالجة اللغات الطبيعية يستهلك وقت (حوالي 6 ثواني للنص الواحد). فبعد عملية الإعراب يقوم الصف بتنبيه مجموعات الميزات هذه والتي تقوم بدورها بتنبيه الميزات فتتحدث قيمها بحسب التغيير الجديد.

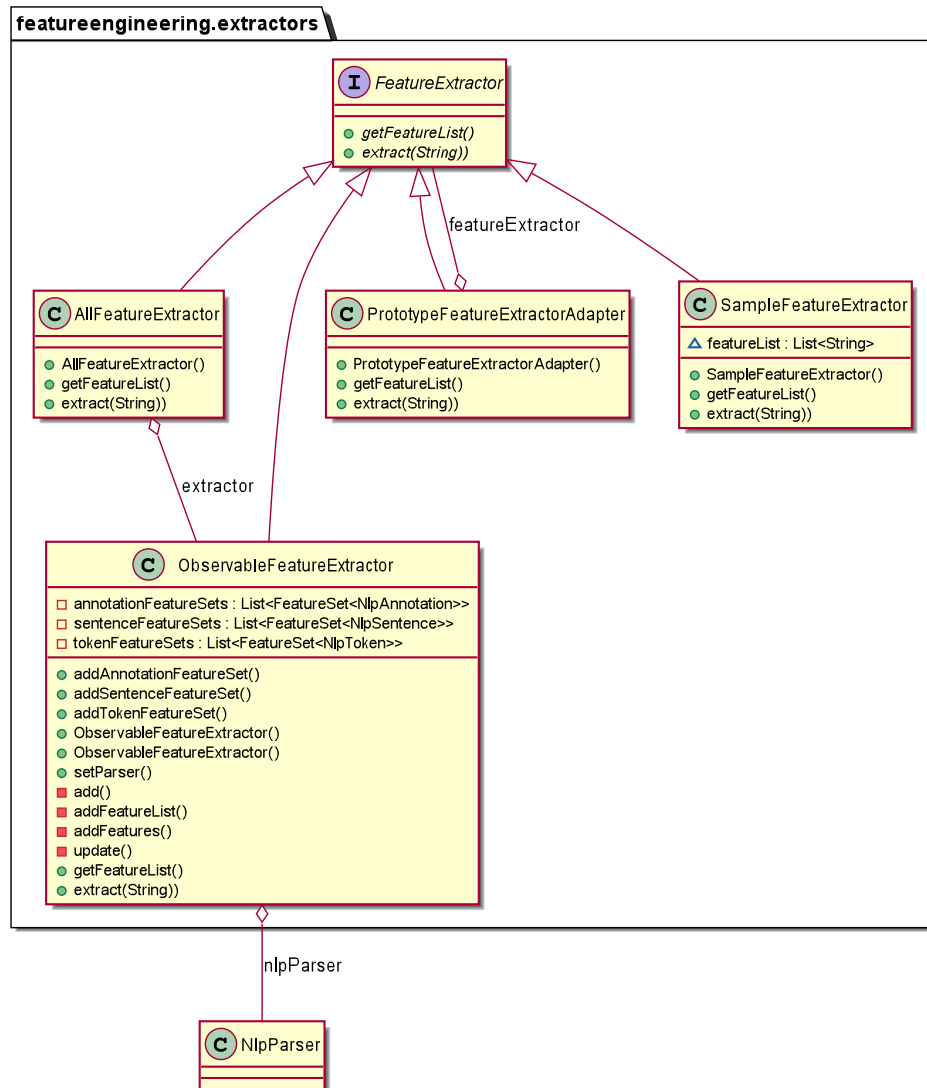
## 5.2.4 الحزمة nlp

تم بناء هذه الحزمة لتغليف وتوحيد الواجهة البرمجية API لمكتبات معالجة اللغات الطبيعية. فلقد استخدمنا في هذا المشروع مكتبة ستانفورد Stanford Parser<sup>1</sup> فهي مكتوبة بلغة جافا. وتقدم جميع الحسابات المطلوبة، ولكنها تستغرق وقت كبير. وإن تصميم الحزمة nlp بهذا الشكل يسمح بتغيير المكتبة المستخدمة لمعالجة اللغات الطبيعية.

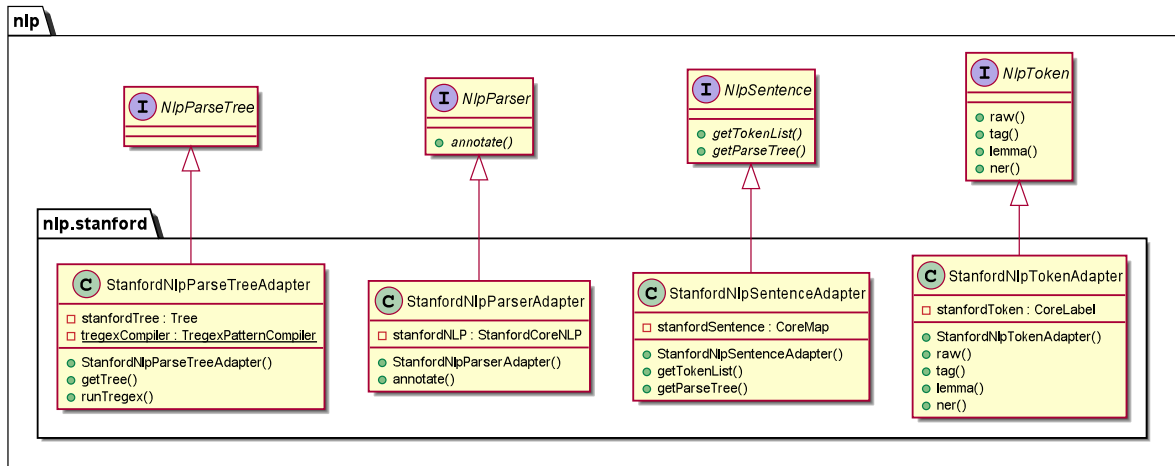
تم استخدام النمط Adapter design pattern لتحقيق ذلك. إذ تم تعريف الواجهات الأساسية والتوابع الأساسية. وللاستخدام مكتبة محددة نقوم بتنفيذ الواجهات السابقة بحسب الواجهة البرمجة API للمكتبة المستخدمة. فبذلك تم عزل المكتبة المستخدمة عن الكود البرمجي المكتوب عن المكتبة المستخدمة. يوضح الشكل 9.4 عينة من مخطط الصفوف لهذه الحزمة.

<sup>1</sup> <https://nlp.stanford.edu/software/lex-parser.shtml>





الشكل 8.4: مخطط الصفوف للحزمة featureengineering.extractors



الشكل 9.4: عينة من مخطط الصفوف للحزمة nlp.

## المراجع

- [1] Mitchell P Marcus, Mary Ann Marcinkiewicz, and Beatrice Santorini. “Building a large annotated corpus of English: The Penn Treebank”. In: *Computational linguistics* 19.2 (1993), pp. 313–330.
- [2] Averil Coxhead. “A new academic word list”. In: *TESOL quarterly* 34.2 (2000), pp. 213–238.
- [3] Sarah E Schwarm and Mari Ostendorf. “Reading level assessment using support vector machines and statistical language models”. In: *Proceedings of the 43rd Annual Meeting on Association for Computational Linguistics*. Association for Computational Linguistics. 2005, pp. 523–530.
- [4] Rong Zheng et al. “A framework for authorship identification of online messages: Writing-style features and classification techniques”. In: *Journal of the American society for information science and technology* 57.3 (2006), pp. 378–393.
- [5] William H DuBay. “The Classic Readability Studies.” In: *Online Submission* (2007).
- [6] Ronald P Reck and Ruth A Reck. “Generating and rendering readability scores for Project Gutenberg texts”. In: *Proceedings of the Corpus Linguistics Conference*. 2007.
- [7] Marie-Catherine De Marneffe and Christopher D Manning. *Stanford typed dependencies manual*. Tech. rep. Technical report, Stanford University, 2008.

- [8] Lijun Feng, Noémie Elhadad, and Matt Huenerfauth. “Cognitively motivated features for readability assessment”. In: *Proceedings of the 12th Conference of the European Chapter of the Association for Computational Linguistics*. Association for Computational Linguistics. 2009, pp. 229–237.
- [9] Sarah E Petersen and Mari Ostendorf. “A machine learning approach to reading level assessment”. In: *Computer speech & language* 23.1 (2009), pp. 89–106.
- [10] Lijun Feng. “Automatic readability assessment”. In: (2010).
- [11] Lijun Feng et al. “A comparison of features for automatic readability assessment”. In: *Proceedings of the 23rd international conference on computational linguistics: Posters*. Association for Computational Linguistics. 2010, pp. 276–284.
- [12] Xiaofei Lu. “Automatic analysis of syntactic complexity in second language writing”. In: *International journal of corpus linguistics* 15.4 (2010), pp. 474–496.
- [13] Scott A Crossley, David B Allen, and Danielle S McNamara. “Text readability and intuitive simplification: A comparison of readability formulas.” In: *Reading in a foreign language* 23.1 (2011), pp. 84–101.
- [14] Scott A Crossley, David Allen, and Danielle S McNamara. “Text simplification and comprehensible input: A case for an intuitive approach”. In: *Language Teaching Research* 16.1 (2012), pp. 89–108.
- [15] Sowmya Vajjala and Detmar Meurers. “On improving the accuracy of readability classification using insights from second language acquisition”. In: *Proceedings of the seventh workshop on building educational applications using NLP*. Association for Computational Linguistics. 2012, pp. 163–173.
- [16] Gareth James et al. *An introduction to statistical learning*. Vol. 112. Springer, 2013.

- [17] Ryszard S Michalski, Jaime G Carbonell, and Tom M Mitchell. *Machine learning: An artificial intelligence approach*. Springer Science & Business Media, 2013.
- [18] Sowmya Vajjala and Detmar Meurers. “Readability assessment for text simplification: From analysing documents to identifying sentential simplifications”. In: *ITL-International Journal of Applied Linguistics* 165.2 (2014), pp. 194–222.
- [19] Johann Schleier-Smith. “An architecture for Agile machine learning in real-time applications”. In: *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM. 2015, pp. 2059–2068.
- [20] D Sculley et al. “Hidden technical debt in machine learning systems”. In: *Advances in neural information processing systems*. 2015, pp. 2503–2511.
- [21] Sowmya Vajjala. “Analyzing text complexity and text simplification: connecting linguistics, processing and educational applications”. PhD thesis. Ph. D. thesis, University of Tübingen, 2015.
- [22] Sowmya Vajjala and Detmar Meurers. “Readability-based sentence ranking for evaluating text simplification”. In: *arXiv preprint arXiv:1603.06009* (2016).
- [23] Ian H Witten et al. *Data Mining: Practical machine learning tools and techniques*. Morgan Kaufmann, 2016.
- [24] Menglin Xia, Ekaterina Kochmar, and Ted Briscoe. “Text readability assessment for second language learners”. In: *Proceedings of the 11th Workshop on Innovative Use of NLP for Building Educational Applications*. 2016, pp. 12–22.
- [25] Aurélien Géron. *Hands-on machine learning with Scikit-Learn and TensorFlow: concepts, tools, and techniques to build intelligent systems*. ” O’Reilly Media, Inc.”, 2017.
- [26] Riad Sonbol. *Extracting Business Process Models from Natural Language Texts*. Higher Institute for Applied Sciences and Technology, 2017.

- [27] Sowmya Vajjala and Ivana Lucic. “OneStopEnglish corpus: A new corpus for automatic readability assessment and text simplification”. In: (2018).